

AULA:

Regressão por Variáveis Instrumentais (VI)

Prof. Victor Hugo Lachos Davila

Motivação para o uso de VI

Vimos anteriormente que:

Sob a hipótese $\text{cov}(u, x) = 0$,

(I) MQO é consistente

Sob a hipótese $E(u|x) = 0$,

(II) MQO é não-viesado

Se essas hipóteses forem violadas, MQO será viesado e inconsistente, sendo necessário buscar um novo método de estimação.

O método de regressão por “**variáveis instrumentais**” (VI) é uma solução possível que fornece estimadores consistentes dos parâmetros de interesse

Principais causas do viés do estimador de MQO

- As razões mais comuns para a existência de correlação entre o distúrbio (u) e alguma variável explicativa (x) são:
 - (1) Omissão de variáveis relevantes
 - (2) Erros de mensuração
 - (3) Simultaneidade

Erros de mensuração

Considere o modelo de regressão simples:

$$y = \beta_0 + \beta_1 x^* + u$$

onde $\text{cov}(x^*, u) = E(x^*u) = 0$.

Nesse modelo, a estimação por MQO deveria gerar estimadores consistentes dos parâmetros.

Supõe-se, porém, que a **variável x^* seja observada com erro**. Isto é, o que observamos na prática é:

$$x = x^* + e$$

onde $E(e) = 0$

$\text{cov}(x^*, e) = E(x^*e) = 0$

$\text{cov}(e, u) = E(eu) = 0$

Exemplo:

- Para explicar o CR de um aluno da UNICAMP, podemos estar interessados em usar como variáveis explicativas (dentre outras): renda familiar, número de horas dedicadas ao estudo, tempo necessário para o trajeto casa-UNICAMP etc.
- Todas essas variáveis estão sujeitas a **erros de mensuração**, pois os alunos podem errar (deliberadamente ou não) ao responder à pesquisa.
- Se os erros forem **puramente aleatórios**, isto é, não estiverem correlacionados com outras variáveis relevantes, as hipóteses do modelo acima serão satisfeitas.

Erros de mensuração

- Reescrevendo o modelo em função da variável observada x:

$$\begin{aligned}y &= \beta_0 + \beta_1 x^* + u = \beta_0 + \beta_1 (x - e) + u = \beta_0 + \beta_1 x + (u - \beta_1 e) \\ &= \beta_0 + \beta_1 x + \varepsilon\end{aligned}$$

- Agora, a estimação por MQO não gera estimadores consistentes dos parâmetros, pois:

$$\begin{aligned}\text{cov}(x, \varepsilon) &= E(x\varepsilon) = E[(x^* + e)(u - \beta_1 e)] \\ &= E[x^*u + eu - \beta_1 x^*e - \beta_1 e^2] = E(x^*u) + E(eu) - \beta_1 E(x^*e) - \beta_1 E(e^2) \\ &= -\beta_1 \sigma_e^2 \\ &\neq 0\end{aligned}$$

- Lembre que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x}) y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) \varepsilon_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

- E note que

$$\text{var}(x) = \text{var}(x^*) + \text{var}(e) = \sigma_{x^*}^2 + \sigma_e^2$$

$$\begin{aligned} \lim(\hat{\beta}_1) &= \beta_1 + \frac{\text{cov}(x, \varepsilon)}{\text{var}(x)} \\ &= \beta_1 - \frac{\beta_1 \sigma_e^2}{\sigma_{x^*}^2 + \sigma_e^2} = \beta_1 \left(1 - \frac{\sigma_e^2}{\sigma_{x^*}^2 + \sigma_e^2} \right) \end{aligned}$$

- Considere a equação:

$$y = \beta_0 + \beta_1 x + \gamma' \mathbf{v} + u$$

onde y a taxa de criminalidade num determinado estado, x é o número de policias e \mathbf{v} é um vetor que inclui outras variáveis relevantes para explicar y , tal que $\text{cov}(\mathbf{v}, u) = 0$.

- Não seria razoável esperar que o “**modelo estrutural**” que relaciona as variáveis acima contivesse uma segunda equação,

$$x = \alpha_0 + \alpha_1 y + \delta' \mathbf{w} + e$$

ou seja, que x também dependesse de y ?

De fato, mostraremos a seguir que, na primeira equação, em geral a condição $\text{cov}(x, u) = 0$ é violada e, portanto, o estimador de MQO é inconsistente.

Simultaneidade

- O fato de que x e u devem ser correlacionados na equação 1 pode ser verificado facilmente, já que
 - (1) quando u varia, y varia na mesma direção, pela equação 1;
 - (2) quando y varia, x também varia, pela equação 2;
 - (3) logo, há correlação entre u e x : **quando u varia, x também varia!**
- Resolvendo o sistema para y e x em função das variáveis exógenas (\mathbf{v} e \mathbf{w}) e dos distúrbios, obtemos a “**forma reduzida**”:

$$y = \frac{1}{1 - \alpha_1 \beta_1} [\beta_0 + \beta_1 \alpha_0 + \beta_1 \boldsymbol{\delta}' \mathbf{w} + \boldsymbol{\gamma}' \mathbf{v} + \beta_1 e + u]$$
$$x = \frac{1}{1 - \alpha_1 \beta_1} [\alpha_0 + \alpha_1 \beta_0 + \alpha_1 \boldsymbol{\gamma}' \mathbf{v} + \boldsymbol{\delta}' \mathbf{w} + \alpha_1 u + e]$$

- Logo, é evidente que, em geral, há correlação entre x e u :

$$\text{cov}(x, u) = E(xu) = \frac{\alpha_1 \sigma_u^2}{1 - \alpha_1 \beta_1} \neq 0$$

- Portanto, o estimador de MQO aplicado à equação 1 é inconsistente!. Esse tipo de viés do estimador de MQO é denominado "**viés de equações simultâneas**" ou simplesmente "**viés de simultaneidade**".

- Outros exemplos:

- Horas trabalhadas X salário médio em determinado setor da indústria (oferta e demanda)
- Consumo de bebidas alcoólicas X desempenho do aluno
- Abertura comercial X crescimento econômico
- Democracia X crescimento econômico
- Corrupção X crescimento econômico

- Considere a equação:

$$y = \beta_0 + \beta_1 x + u \quad (*)$$

onde: $E(u) = 0$
 $\text{cov}(x, u) \neq 0$

- Independentemente do motivo para a existência de correlação entre x e u , o método de **variáveis instrumentais (VI)** fornece um estimador consistente dos parâmetros de interesse.
- O método se baseia na utilização de uma variável adicional z , não incluída em (*), que satisfaça tais condições:

$$(1) \text{Cov}(z, u) = 0$$

$$(2) \text{Cov}(z, x) \neq 0.$$

- Quando uma variável z satisfaz ambas as condições acima, dizemos que z é um **instrumento válido** para x .
- Vale notar que a condição (1) **não é testável**, pois refere-se à covariância entre z e um erro **não observável**
- Você precisa de uma boa “historinha” para justificar seu instrumento!
- A condição (2), porém, **pode ser testada** em uma regressão de x em z [teste de significância de qual coeficiente?]
- Vimos pela Lei dos Grandes números:

$$p \lim(\hat{\beta}_1^{VI}) = \frac{\text{cov}(z, y)}{\text{cov}(z, x)} = \beta_1$$

- Logo, vemos que um instrumento válido permite efetivamente obter um estimador consistente do parâmetro

Variáveis Instrumentais

- Infelizmente, não é sempre fácil encontrar instrumentos válidos para nossos modelos. Na verdade, é muito difícil!
- Uma das razões dessa dificuldade reside no fato de que as **duas condições** requeridas de um instrumento são muitas vezes **conflitantes**
- Exemplo: estimação de equação de salário em função da educação
 - **Variável omitida**: “habilidade” do indivíduo – vieso coeficiente da educação
 - **Possível instrumento**: educação da mãe (correlacionada com a educação do indivíduo)
 - **Mas**: educação da mãe também deve ser correlacionada com a habilidade do indivíduo presente no erro!

- Pode-se mostrar que

$$\text{var}(\hat{\beta}_1^{VI}) = \frac{\text{var}(u)}{n \text{ var}(x) [\text{corr}(x, z)]^2}$$

- Por essa razão, devemos procurar um instrumento que tenha a mais alta correlação possível com x

Mínimos Quadrados em 2 Estágios

- Suponha que temos **dois instrumentos válidos** para a “variável endógena” x .
- Ou seja, temos o modelo

$$y = \beta_0 + \beta_1 x + u \quad (*)$$

- onde:
 $E(u) = 0$
 $\text{cov}(x, u) \neq 0$
 $\text{cov}(z_1, u) = 0; \text{cov}(z_1, x) \neq 0$
 $\text{cov}(z_2, u) = 0; \text{cov}(z_2, x) \neq 0$
- Será melhor usar z_1 ou z_2 como instrumento?. A resposta é: **melhor usar os dois!**.
- É Claro que devemos escolher a combinação linear de z_1 e z_2 com a maior correlação possível com x .
- Além disso, como z_1 e z_2 tem correlação zero com u , qualquer combinação linear dessas variáveis também terá correlação zero com u . Assim, temos um **instrumento válido** “relativamente eficiente”